

AlexNet 논문 리뷰

논문: *ImageNet Classification with Deep Convolutional Neural Networks*

저자: Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton

발표: 2012

원문: [NeurIPS PDF](#)

AlexNet

이 논문은 ImageNet 이미지 분류 문제를 대상으로, 큰 규모의 CNN을 직접 학습한 연구다. 이 논문에서는 1,000개 범주와 약 120만 장의 이미지로 모델을 훈련했고, ILSVRC-2010에서 Top-5 오류율 17.0%를 기록했다. 이후 ILSVRC-2012에서는 여러 모델의 예측을 합쳐 Top-5 오류율을 15.3%까지 낮췄다.

논문에서 주목할 부분은 모델을 크게 만든 것만이 아니다. ReLU로 학습 속도를 높이고, 두 GPU에 모델을 나눠 올렸으며, 데이터 증강과 dropout으로 과적합을 줄였다. 더 넓게 보면, 기존 컴퓨터 비전이 SIFT처럼 사람이 설계한 특징에 크게 의존했던 흐름에서 벗어나, 이미지에 유용한 특징 자체를 대규모 데이터로부터 학습할 수 있음을 보여준 전환점이다.

Abstract

이 논문에서는 ImageNet LSVRC-2010의 1,000개 클래스를 분류하기 위해 큰 CNN을 학습했다. 모델은 합성곱층 5개, 완전연결층 3개로 구성되며, 약 6,000만 개의 파라미터와 65만 개의 뉴런을 가진다.

학습을 빠르게 하기 위해 ReLU와 GPU 기반 합성곱 구현을 사용했다. 과적합을 줄이기 위해서는 완전연결층에 dropout을 적용했다. ILSVRC-2010 테스트에서는 Top-1 오류율 37.5%, Top-5 오류율 17.0%를 기록했다. ILSVRC-2012의 최종 양상블 모델은 Top-5 오류율 15.3%를 기록했다.

1. Introduction

이미지 분류 성능을 높이려면 더 많은 데이터, 더 큰 모델, 그리고 과적합을 줄이는 방법이 필요하다. 당시 널리 쓰이던 이미지 데이터셋은 수만 장 규모였다. 하지만 실제 사진 속 물체는 자세, 조명, 배경이 계속 달라진다. 이런 변화를 모델이 학습하려면 더 많은 예제가 필요하다.

ImageNet은 2만 2천여 범주에 1,500만 장 이상의 고해상도 라벨 이미지를 모아 둔 데이터셋이다. 이 논문에서는 이 정도 규모의 데이터와 GPU 기반 2D 합성곱 구현이 있으면 큰 CNN도 학습할 수 있다고 봤다.

논문에서는 모델의 깊이도 중요하다고 말한다. 실제로 중간 합성곱층 하나를 제거하면 성능이 떨어졌다. 각 합성곱층이 전체 파라미터에서 차지하는 비율은 작지만, 층을 빼면 결과는 나빠졌다.

2. The Dataset

ImageNet과 ILSVRC

ImageNet 전체는 2만 2천여 범주와 1,500만 장 이상의 이미지로 구성된다. 이 논문은 그중 ILSVRC에 사용된 부분을 학습했다.

구분	규모
클래스 수	1,000개
학습 이미지	약 120만 장
검증 이미지	5만 장
테스트 이미지	15만 장

ILSVRC-2010은 테스트 라벨이 공개된 버전이라서, 논문의 대부분 실험은 이 데이터로 진행했다. ILSVRC-2012의 테스트 라벨은 공개되지 않았기 때문에, 일부 결과는 검증 오류율로 비교했다.

입력 이미지 준비

ImageNet 이미지는 크기가 제각각이다. 이 논문에서는 먼저 이미지의 짧은 변을 256 픽셀로 맞췄다. 그다음 `224 x 224` 크기의 이미지를 모델 입력으로 사용했다. 픽셀값에서는 학습 데이터 전체의 평균값만 뺀다. 즉, 별도의 복잡한 전처리 없이 평균을 뺀 RGB 값을 입력으로 사용했다.

Top-1, Top-5 오류율


- **Top-1 오류율**은 모델이 가장 높은 확률로 고른 한 개의 클래스가 틀린 비율이다.
- **Top-5 오류율**은 모델이 제시한 상위 다섯 개 클래스 안에 정답이 없는 비율이다.

두 지표 모두 낮을수록 좋다.

ImageNet처럼 시각적으로 비슷한 세부 범주가 많고 한 이미지에 여러 물체가 함께 나타날 수 있는 데이터에서는, 정답이 상위 5개 후보에 들어오는 지를 보는 Top-5 지표도 유용하다. 다만 실제 단일 정답 분류 시스템을 평가할 때는 Top-1 성능이 더 직접적인 기준이 된다.

3. The Architecture

AlexNet은 학습 가능한 층이 총 8개다. 앞의 다섯 층은 합성곱층이고, 뒤의 세 층은 완전연결층이다. 마지막 층은 1,000개 클래스의 확률을 만들기 위해 1,000-way Softmax로 연결된다.



*그림 1. 논문 Figure 2. 위와 아래 부분은 두 GPU가 각각 처리한 층이다. 두 GPU는 특정 층에서만 통신한다. *

층	구성
입력	224 x 224 x 3 RGB 이미지
Conv1	11 x 11 x 3 필터 96개, stride 4
Conv2	5 x 5 x 48 필터 256개
Conv3	3 x 3 x 256 필터 384개
Conv4	3 x 3 x 192 필터 384개
Conv5	3 x 3 x 192 필터 256개
FC6	뉴런 4,096개
FC7	뉴런 4,096개
FC8	뉴런 1,000개

전체 모델에는 약 6,000만 개의 파라미터와 65만 개의 뉴런이 있다.

3.1 ReLU Nonlinearity

기존 신경망에서는 tanh나 sigmoid를 활성화 함수로 많이 썼다. AlexNet은 대신 다음과 같은 ReLU를 사용했다.

$$f(x) = \max(0, x)$$

논문에서는 CIFAR-10으로 ReLU와 tanh를 비교했다. ReLU를 사용한 4층 CNN은 tanh를 사용한 같은 구조의 CNN보다 학습 오류율 25%에 약 6배 빠르게 도달했다.

그 이유는 sigmoid나 tanh가 입력값이 매우 크거나 작아질 때 기울기가 거의 0이 되는 포화 현상을 보이기 때문이다. 반면 ReLU는 양수 구간에서 기울기가 유지되므로 역전파 신호가 더 잘 전달된다. 이것이 매우 깊거나 큰 모델을 현실적인 시간 안에 학습할 수 있게 한 핵심 요인 중 하나다.

3.2 Training on Multiple GPUs

당시 GTX 580 GPU 한 대의 메모리는 3GB였다. 모델이 한 GPU에 들어가지 않았기 때문에, 이 논문에서는 필터와 뉴런을 두 GPU로 나눴다.

두 번째, 네 번째, 다섯 번째 합성곱층은 같은 GPU에 있는 이전 층의 특징 맵만 입력으로 받는다. 반면 세 번째 합성곱층은 두 GPU의 특징 맵을 모두 받고, 완전연결층은 이전 층의 모든 뉴런과 연결된다.

이 구조는 비교한 단일 GPU 모델보다 Top-1 오류율을 1.7%p, Top-5 오류율을 1.2%p 낮췄다. 학습 시간도 단일 GPU 모델보다 약간 짧았다.

이는 오늘날 여러 GPU가 같은 모델 사본을 나눠 학습하는 데이터 병렬화와는 다르다. 당시에는 한 GPU의 메모리에 모델 전체가 들어가지 않았기 때문에, 모델 자체를 GPU 둘로 분할하는 모델 병렬화가 필요했다. GPU 간 통신을 특정 층으로 제한한 것은 통신 비용 때문에 계산 속도가 느려지는 문제를 피하려는 설계다.

3.3 Local Response Normalization

LRN(Local Response Normalization)은 같은 위치에서 여러 필터가 낸 큰 활성화값이 서로 경쟁하도록 하는 방식이다. 논문에서는 ReLU에 입력 정규화가 꼭 필요하지는 않지만, LRN을 추가하면 일반화에 도움이 된다고 설명한다.

LRN을 넣었을 때 Top-1 오류율은 1.4%p, Top-5 오류율은 1.2%p 줄었다. CIFAR-10에서는 정규화 없이 13%였던 테스트 오류율이 LRN을 적용했을 때 11%가 됐다.

다만 LRN은 AlexNet 당시에는 성능 향상에 도움이 되었지만, 현재의 CNN에서는 Batch Normalization이나 Layer Normalization 같은 방법이 더 널리 사용된다. 따라서 LRN은 현대 표준 기법이라기보다, 당시 대규모 CNN 학습을 안정화하기 위해 시도된 중요한 역사적 구성요소로 보는 편이 적절하다.

3.4 Overlapping Pooling

일반적인 풀링은 인접한 풀링 영역이 겹치지 않게 설정할 수 있다. AlexNet은 풀링 크기 3, stride 2를 사용해 인접한 영역이 겹치도록 했다.

이 논문에서는 이 방식을 겹치지 않는 풀링보다 Top-1 오류율을 0.4%p, Top-5 오류율을 0.3%p 낮추는 방법으로 보고했다. 또한 학습 과정에서 겹치는 풀링을 쓴 모델이 과적합되기 조금 더 어렵다는 점도 관찰했다.

풀링은 특징 맵의 크기를 줄여 계산량을 낮추고, 물체 위치가 조금 바뀌어도 비슷하게 인식하도록 돕는다. 다만 정보를 줄이는 연산이기도 하므로, AlexNet 이후의 많은 모델은 작은 합성곱 필터를 여러 층 쌓거나 stride를 조절해 공간 정보를 더 오래 유지하는 방향으로 발전했다.

3.5 Overall Architecture

각 합성곱층과 완전연결층의 출력에는 ReLU를 적용한다. 첫 번째와 두 번째 합성곱층 뒤에는 LRN과 Max Pooling을 붙였고, 다섯 번째 합성곱층 뒤에도 Max Pooling을 붙였다.

```
입력 (224 x 224 x 3)
→ Conv1 → ReLU → LRN → Max Pooling
→ Conv2 → ReLU → LRN → Max Pooling
→ Conv3 → ReLU
→ Conv4 → ReLU
→ Conv5 → ReLU → Max Pooling
→ FC(4096) → ReLU → Dropout
→ FC(4096) → ReLU → Dropout
→ FC(1000) → Softmax
```

4. Reducing Overfitting

모델에는 약 6,000만 개의 파라미터가 있다. 120만 장의 학습 이미지가 있어도 이 정도 파라미터를 학습하면 과적합이 문제가 될 수 있다. 이 논문에서는 데이터 증강과 dropout을 사용했다.

4.1 Data Augmentation

첫 번째 방법은 256 x 256 이미지에서 무작위 224 x 224 패치를 뽑고, 좌우 반전도 함께 적용하는 것이다. 테스트할 때는 네 모서리와 중앙에서 얻은 다섯 패치, 그리고 각각을 좌우 반전한 패치까지 총 10개를 사용했다. 최종 예측은 이 10개 패치의 Softmax 출력을 평균내서 만들었다.

두 번째 방법은 RGB 색상값을 바꾸는 것이다. 학습 이미지의 RGB 픽셀값에 PCA를 적용하고, 각 이미지의 색상에 주성분 방향의 무작위 변화를 더했다. 논문에서는 이 방법으로 Top-1 오류율이 1% 이상 줄었다고 보고했다.

랜덤 크롭과 좌우 반전은 같은 물체가 이미지의 어느 위치에 있거나 좌우로 뒤집혀 있어도 같은 클래스로 판단해야 한다는 성질을 학습시키는 방법이다. 색상 변화도 조명이나 카메라 환경이 달라져도 물체의 정체성은 유지된다는 점을 반영한다. 즉, 데이터 증강은 학습 데이터를 단순히 늘리는 것이 아니라 모델이 가져야 할 불변성을 직접 주입하는 방식이다.

4.2 Dropout

dropout은 학습 중 일부 은닉 뉴런의 출력을 0으로 만드는 방법이다. AlexNet은 첫 두 완전연결층에서 각 뉴런을 확률 0.5로 끈다. 꺼진 뉴런은 순전파와 역전파에 참여하지 않는다.

```
학습할 때
  각 은닉 뉴런을 확률 0.5로 끈다.

테스트할 때
  모든 뉴런을 사용한다.
  각 뉴런의 출력에 0.5를 곱한다.
```

논문은 dropout이 뉴런 사이의 복잡한 의존을 줄이고, 더 견고한 특징을 학습하게 한다고 설명한다. 대신 수렴에 필요한 반복 횟수는 대략 두 배가 된다.

직관적으로 dropout은 매 학습 단계마다 일부 뉴런을 제거한 서로 다른 작은 네트워크를 학습시키고, 테스트 시에는 이들을 평균내는 효과를 낸다. 그래서 특정 뉴런 조합에만 의존하는 것을 막아 일반화 성능을 높인다. AlexNet에서는 특히 파라미터가 많은 완전연결층의 과적합을 줄이는 역할을 했다.

5. Details of Learning

학습에는 확률적 경사하강법(SGD)을 사용했다.

항목	설정
배치 크기	128
모멘텀	0.9
Weight decay	0.0005
초기 학습률	0.01
학습률 조절	검증 오류가 더 이상 줄지 않으면 1/10로 감소
학습 횟수	약 90 epoch
학습 시간	GTX 580 3GB GPU 2대에서 5-6일

가중치는 평균 0, 표준편차 0.01인 가우시안 분포에서 초기화했다. 두 번째·네 번째·다섯 번째 합성곱층과 완전연결 은닉층의 bias는 1로 시작했고, 나머지 bias는 0으로 시작했다. 학습률은 0.01에서 시작해, 검증 오류가 개선되지 않을 때마다 10분의 1로 낮췄다. 학습이 끝날 때까지 학습률은 세 번 감소했다.

6. Results

ILSVRC-2010

방법	Top-1 오류율	Top-5 오류율
Sparse coding	47.1%	28.2%
SIFT + Fisher Vectors	45.7%	25.7%
CNN	37.5%	17.0%

논문의 CNN은 ILSVRC-2010에서 Top-1 오류율 37.5%, Top-5 오류율 17.0%를 기록했다.

이는 당시 강력한 전통적 특징 기반 방식인 SIFT + Fisher Vectors의 Top-5 오류율 25.7%보다 8.7%p 낮은 수치다. 단순한 소폭 개선이 아니라, 대규모 이미지 인식에서 특징을 수작업으로 설계하는 방식보다 CNN 기반 표현 학습이 훨씬 강력할 수 있음을 보여준 결과였다.

ILSVRC-2012

모델	Top-1 오류율(검증)	Top-5 오류율(검증)	Top-5 오류율(테스트)
SIFT + Fisher Vectors	-	-	26.2%
CNN 1개	40.7%	18.2%	-
CNN 5개 평균	38.1%	16.4%	16.4%
사전학습 CNN을 포함한 7개 평균	36.7%	15.4%	15.3%

단일 CNN의 Top-5 오류율은 18.2%였다. 비슷한 CNN 다섯 개의 예측을 평균내면 16.4%가 됐다. ImageNet Fall 2011 전체 데이터로 사전학습한 두 모델까지 더해 총 일곱 모델의 예측을 평균냈을 때, 테스트 오류율은 15.3%가 됐다.

6.1 Qualitative Evaluations




그림 2. 논문 Figure 4. 왼쪽은 테스트 이미지의 Top-5 예측이다. 오른쪽은 마지막 은닉층의 특징 벡터가 가까운 학습 이미지를 찾은 결과다.

첫 번째 합성곱층의 필터를 보면 방향과 주파수에 반응하는 패턴, 색상 블롭 등이 나타난다. 두 GPU가 학습한 필터도 차이를 보였다. 첫 번째 GPU의 필터는 대체로 색상에 덜 특이적이었고, 두 번째 GPU의 필터는 색상에 더 특이적이었다.

이 논문에서는 마지막 4,096차원 은닉층의 벡터도 살펴봤다. 테스트 이미지와 학습 이미지 사이의 유클리드 거리를 계산했더니, 픽셀 모양은 달라도 비슷한 물체나 자세를 가진 이미지가 가까이 나오는 사례가 있었다.

7. Discussion

중간 합성곱층을 하나 빼면 Top-1 성능이 약 2% 낮아졌다. 이 논문에서는 이 결과를 바탕으로 네트워크의 깊이가 결과에 중요하다고 설명한다.

실험을 단순하게 하기 위해 비지도 사전학습은 사용하지 않았다. 다만 모델만 커지고 라벨 데이터가 그만큼 늘지 않는 상황에서는 비지도 사전학습이 도움이 될 수 있다고 언급했다.

이 논문에서는 모델을 더 크게 만들고 더 오래 학습할수록 결과가 좋아졌다고 설명한다. 더 빠른 GPU와 더 큰 데이터셋을 쓸 수 있다면 성능도 더 좋아질 수 있다고 봤다. 마지막으로 정지 이미지뿐 아니라 시간 정보가 있는 비디오에 큰 CNN을 적용하는 방향을 제안했다.

정리

AlexNet은 큰 CNN을 ImageNet에 학습하기 위해 ReLU, 두 GPU 분할, LRN, Overlapping Pooling, 데이터 증강, dropout을 함께 사용했다. 논문에서 제시한 대표 결과는 ILSVRC-2010의 Top-5 오류율 17.0%와 ILSVRC-2012 최종 앙상블의 Top-5 오류율 15.3%다.

AlexNet의 핵심 의의는 CNN 자체를 처음 제안했다는 데 있지 않다. 대규모 데이터, GPU 연산, 깊은 네트워크, 효과적인 학습 기법을 결합하면 CNN이 전통적인 특징 기반 방식보다 훨씬 뛰어난 성능을 낼 수 있음을 설득력 있게 입증했다는 데 있다. LRN이나 당시의 2-GPU 분할 방식처럼 지금은 널리 쓰이지 않는 요소도 있지만, 데이터와 연산 규모를 키우며 표현을 학습하는 현대 딥러닝의 방향을 확립했다는 점에서 중요하다.